

2.什么是NPU？ 与CPU/GPU的区别

1. NPU/CPU/GPU是什么

NPU定义

NPU（Neural Processing Unit，神经网络处理单元）是专为人工智能计算而设计的专用处理器，其核心优势在于高效执行深度学习所依赖的大规模并行矩阵计算。相较于通用型CPU与侧重图形渲染的GPU，NPU通过架构层面的深度定制，对神经网络的推理过程（部分设计亦支持训练）实现了针对性优化，从而在低功耗条件下提供显著的AI算力提升。


NPU的加入显著分担了系统主处理器的计算压力。在典型工作流中，CPU负责整体调度：将图形处理任务分配给GPU，而将人脸识别、语音分析等AI任务定向调度至NPU，从而提升系统能效。

目前，NPU已广泛应用于智能终端，支撑着人脸跟踪、图像分类、语音识别、视频分析、辅助驾驶等场景的实时AI处理需求。

NPU/CPU/GPU对比


处理器	CPU（中央处理器）	GPU（图形处理器）	NPU（神经网络处理器）
全称	Central Processing Unit	Graphics Processing Unit	Neural Processing Unit
主要用途	通用计算、系统控制、任务调度	图形渲染、并行计算	专用于人工智能/深度学习推理与训练
核心特点	少量高性能核心（通常 2-64 核） 高单线程性能 低延迟响应	大量小核心（数千个 CUDA/流处理器） 高吞吐量 擅长并行任务	高度定制化架构 针对矩阵/张量运算优化 能效比高
并行能力	弱（侧重串行任务）	极强（大规模数据并行）	强（专为神经网络并行结构设计）
典型应用场景	操作系统运行、办公软件、网页浏览、程序编译等	游戏渲染、视频编辑、科学计算等	智能驾驶、端侧ai、边缘ai等
厂商/产品	Intel Core / AMD Ryzen / Apple M 系列 CPU	NVIDIA GeForce / AMD Radeon / Apple M 系列 GPU	华为昇腾（Ascend）NPU / Apple Neural Engine / 高通 Hexagon NPU / Google TPU

CPU/GPU/NPU结构图



2. RKNPU介绍

RKNPU 经过了几代的发展，首代初次引入了 RKNPU 是从 RK3399pro 和 RK1808 开始的，相比传统的 CPU 和 GPU，在深度学习运算能力上有比较大幅度的提升。接下来在 RV1109 和 RV1126 上使用了第二代 NPU，提升了 NPU 的利用率。第三代 NPU 应用在 RK3566 和 RK3568 上，搭载全新 NPU 自研架构。第四代 NPU 应用在 RK3588 和 RK3588s 上，自研架构再升级。RKNPU 发展过程如下图所示：



瑞芯微 RK3588 芯片内置 NPU，是 RKNPU 第四代的代表产品。第四代 RKNPU 特点如下所示：

- (1) 拥有三个 NPU 核心
- (2) 支持三核协同工作，双核协同工作和独立工作
- (3) 使用 AHB 接口配置 NPU
- (4) 使用 AXI 接口从内存中获取数据
- (5) 支持 int4、int8、int16、float16、Bfloat16 和 tf32 操作
- (6) 每个周期可进行 1024x3 个 int8 MAC 操作
- (7) 每个周期可进行 512x3 个 int16 MAC 操作
- (8) 每个周期可进行 512x3 个 float16 MAC 操作

- (9) 每个周期可进行 512x3 个 bfloat16 MAC 操作
- (10) 每个周期可进行 256x3 个 tf32 MAC 操作
- (11) 每个周期可进行 2048x3 个 int4 MAC 操作
- (12) 每个核心有 384KB 的内部缓存
- (13) 支持转换的推理模型：TensorFlow、Caffe、Tflite、Pytorch、Onnx等

3. NPU算力计算方法

算力即计算能力。

- 1 TOPS（Tera Operation Per Second）表示处理器每秒可以进行一万亿次的操作（OP）。
- 1 TFLOPS表示处理器每秒可以完成一万亿次浮点运算操作。
- 操作（Operator，简称OP），算子或者操作，是对函数进行的任何一种操作的统称，比如我们最常见的加、减、乘、除、微分、求梯度等等函数，它们就是一个个算子或者操作。

TOPS是一个更广泛的算力性能度量单位。TOPS和TFLOPS属于两种不同的维度描述，两者之间一般没有绝对的换算关系。

每个周期的**理论峰值性能**为 $Perf=MACs*2(ops/cycle)$ 。其中 MACs 表示每个周期内可以达到的乘加操作次数，在前面已经对单个周期的每个数据类型可以进行的**乘加**操作次数进行了列举，而算力指的是运算的次数，所以要将乘加操作分解为一次乘法和一次加法，也就是最后乘以 2 的由来。当 NPU 的频率为 f 时，则每秒的理论峰值性能 为 $Perf=MACs*2*f(ops/s)$ 。

三核NN工作模式	MAC能力			
	INT8	INT16/FP16/BF16	INT4	TF32
单核模式 (1+1+1)	1024 + 1024 + 1024	512 + 512 + 512	2048 + 2048 +2048	256 + 256 +256
双核模式 (2+1)	2048 + 1024	1024 + 512	4096 + 2048	512 + 256
三核模式 (3)	3072	1536	6144	768
总算力（TOPS）	6	3	12	1.5

以 RK3588 int 8 数据类型为例进行性能计算演示：

- (1) RK3588 每个周期可进行 1024x3 个 int8 MAC 操作
- (2) RK3588 的 NPU 运行频率为 1G HZ
- (3) 理论峰值性能计算公式为 $Perf=MACs*2*f(ops/s)$

综上 RK3588 int 8 理论峰值性能为 $Perf=1024x3x2x1G = 6 TOPS$ 。其他类型的算力计算同理。