

# 4.瑞芯微原厂NPU资料介绍

## 1. github仓库介绍

官网地址: <https://github.com/airockchip>

The screenshot shows the GitHub profile of 'airockchip'. The profile includes a repository grid with the following items:

- rknn-toolkit2** (Public): C, 2.5k stars, 284 forks
- rknn\_model\_zoo** (Public): C, 2.2k stars, 371 forks
- rknn-llm** (Public): Python, 1.2k stars, 158 forks
- librga** (Public): C, 503 stars, 86 forks
- ultralytics\_yolov8** (Public template): Forked from ultralytics/ultralytics, NEW - YOLOv8 in PyTorch > ONNX > CoreML > TFLite, Python, 303 stars, 62 forks
- yolov5** (Public): Forked from ultralytics/yolov5, YOLOv5 in PyTorch > ONNX > CoreML > TFLite, Python, 265 stars, 55 forks

The profile also shows a '0 contributions in the last year' chart and a 'Follow' button.

## rknn-toolkit2

The screenshot shows the GitHub repository page for 'rknn-toolkit2'. The repository is public and has 2.5k stars, 284 forks, and 32 watchers. The file list shows the following items:

- autosparsity**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103B/... 2 years ago
- doc**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103B/... 9 months ago
- res**: Update README: Add description for QQ Group 4 10 months ago
- rknn-toolkit-lite2**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103B/... 9 months ago
- rknn-toolkit2**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103B/... 9 months ago
- rknpu2**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103B/... 9 months ago
- .gitignore**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103/R... 2 years ago
- CHANGELOG.md**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103B/... 9 months ago
- LICENSE**: Update LICENSE 6 months ago
- README.md**: Update RK3562/RK3566/RK3568/RK3576/RK3588/RV1103B/... 9 months ago

Red arrows point to the **doc**, **rknn-toolkit-lite2**, **rknn-toolkit2**, and **rknpu2** directories.

在 rknn-toolkit2 仓库中提供了三个工具套件，分别为 **rknn-toolkit2**、**rknn-toolkit-lite2** 和 **rknpu2**，其中 rknn-toolkit-lite2 和 rknpu2 可以分为一类，都只能在开发板上运行，只是调用的接口

不同，rknn-toolkit-lite2 调用的是 Python 接口，rknnpu2 调用的是 C++接口，通过这两种方式都可以调用 SCO 的 NPU 实现加速推理，但前提是需要将训练出来的常用模型转换为瑞芯微支持的 RKNN 模型，而 RKNN 模型的转换需要用到 rknn-toolkit2。

### **rknn\_model\_zoo**

rknn\_model\_zoo 实际上就是将一系列主流算法整合起来并部署到 RK SOC 的综合例程，包含了模型的转换、模型的 Python api 推理、模型的 C api 推理。用户可以直接下载并在 RK 平台上运行，无需自己训练或转换。

### **rknn-llm**

专为在瑞芯微芯片上运行 轻量级大语言模型（LLM）而设计，支持本地化部署。

### **librga**

Rockchip Graphics Accelerator（RGA）是瑞芯微芯片内置的 图形处理单元，librga是其 C/C++ 接口库，用于高效执行图像变换操作。

### **ultralytics\_yolov8**

基于 Ultralytics 官方 YOLOv8 项目的一个 分支版本，专门为瑞芯微平台进行了优化和适配。

### **yolov5**

同样是基于 Ultralytics 官方 YOLOv5 的分支，专为瑞芯微平台优化。

## **2. rknn-toolkit2介绍**

rknn-toolkit2仓库链接为：<https://github.com/airockchip/rknn-toolkit2/tree/master/rknn-toolkit2>

### **rknn-toolkit2目录说明：**

- 1.docs：版本的更新的日志信息。
- 2.docker：存放构建docker的dockerfile文件。
- 3.examples：存放了caffe、darknet、functions、onnx、pytorch、tensorflow、tflite等模型转换、连板推理例程。
- 4.packages：存放了各个python版本要装的依赖项文件以及各个python版本的rknn\_toolkit2 whl文件。

RKNN-Toolkit2总共有支持两种不同的版本，一种是x86版本，另外一种是ARM64版本。两个版本的安装教程都一样，除了ARM64版本不支持docker安装。除此之外，ARM64版本仅支持转换模型时使用 onnx和pytorch框架下的模型，其他框架的模型暂时不支持。

目前RKNN-Toolkit2的2个版本所支持深度学习框架的差异：

| 深度学习框架     | x86版本 | ARM64版本 |
|------------|-------|---------|
| Caffe      | ✓     | ✗       |
| TensorFlow | ✓     | ✗       |
| TF Lite    | ✓     | ✗       |
| ONNX       | ✓     | ✓       |
| DarkNet    | ✓     | ✗       |
| PyTorch    | ✓     | ✓       |

两者所依赖的工具差异：

| 依赖工具         | x86版本 | ARM64版本 |
|--------------|-------|---------|
| adb          | ✓     | ✗       |
| rknn_server  | ✓     | ✗       |
| rknn runtime | ✓     | ✓       |

两个版本使用差异：

主要差异在于调试功能包含精度分析，连板调试，内存和性能分析部分，ARM64版本直接在Linux系统的板端安装之后，只需直接使用上述对应功能，不需要启动**rknn\_server**，只需保证板端上的 /usr/lib64 有对应的 librknnrt.so，即可调用调试功能。由于ARM64版本不支持adb，所以所有调试功能都仅能在当前板端使用。x86版本需要更新并启动rknn\_server，并且支持adb功能连接其他设备所以需保证adb正常使用状态下才能使用调试功能。

除此之外，x86版本和ARM64版本可能会存在性能差异，特别是在精度分析上或者使用大量图片做量化的情况下。

**rknn-toolkit2工具提供的Python接口可以便捷地完成以下功能：**

1. 模型转换：支持将PyTorch、ONNX、TensorFlow、TensorFlow Lite、Caffe、DarkNet等模型转为RKNN模型。
2. 量化功能：支持将浮点模型量化为定点模型，并支持混合量化。
3. 模型推理：将RKNN模型分发到指定的NPU设备上推理并获取推理结果；或在计算机上仿真NPU运行RKNN模型并获取推理结果。
4. 性能和内存评估：将RKNN模型分发到指定NPU设备上运行，以评估模型在实际设备上运行时的性能和内存占用情况。

5. 量化精度分析：该功能将给出模型量化后每一层推理结果与浮点模型推理结果的余弦距离和欧氏距离，以便于分析量化误差是如何出现的，为提高量化模型的精度提供思路。
6. 模型加密功能：使用指定的加密等级将RKNN模型整体加密。

### 3. rknn-toolkit-lite2介绍

rknn-toolkit-lite2仓库链接为：<https://github.com/airockchip/rknn-toolkit2/tree/master/rknn-toolkit-lite2>

**rknn-toolkit-lite2目录说明：**

1.example：存放了dynamic\_shape、resnet18两个模型部署推理例程。

2.packages：存放了各个python版本的rknn\_toolkit\_lite2 whl文件。

RKNN-Toolkit-Lite2 工具属于 RKNN-Toolkit2 的阉割版本，只保留了**模型推理**的功能，并且他们的运行环境不同，RKNN-Toolkit-Lite2 只能运行在 arm 架构的开发板上，而 RKNN-Toolkit2 可以运行在 X86 架构和arm架构上。具体差异如下：

|        | rknn-toolkit2     | rknn-toolkit-lite2 |
|--------|-------------------|--------------------|
| 运行平台   | X86或ARM架构的Linux系统 | ARM架构的Linux系统（开发板） |
| 使用语言   | Python            | Python             |
| 模型推理   | 支持                | 支持                 |
| 模型转换   | 支持                | 不支持                |
| 性能评估   | 支持                | 不支持                |
| 内存评估   | 支持                | 不支持                |
| 量化精度分析 | 支持                | 不支持                |

### 4. rknpu2介绍

rknpu2仓库链接为：<https://github.com/airockchip/rknn-toolkit2/tree/master/rknpu2>

RKNPU2 与 RKNN-Toolkit-Lite2 的功能类似，也是只能在开发板上运行，实现 RKNN 模型的部署和推理，唯一不同的区别就是调用的接口不同，RKNN-Toolkit-Lite2 调用的是 Python接口，而 RKNPU2 调用的是 C++接口，C++相较于 Python 会有更高的性能，所以一般在实际的使用中，**大多数都是使用 RKNPU2 进行模型部署和推理，RKNN-Toolkit-Lite2 只适用于前期的验证测试。**


**rknpu2目录说明：**

- 1.example：存放了CAPI编写的一些模型部署推理例程。
- 2.runtime：存放运行时库，以及编写C 例程要用到的头文件和对应的so动态库。


非常重要：它是让模型在瑞芯微芯片上“真正跑起来”的核心软件组件。

RKNN Runtime负责加载RKNN模型，并调用NPU驱动实现在NPU上推理RKNN模型。推理RKNN模型时，包括原始数据输入预处理、NPU运行模型、输出后处理三项流程。根据不同模型输入格式和量化方式，RKNN Runtime提供通用API和零拷贝API两种处理流程。

(1) 通用API推理：提供一套简洁、无门槛的推理API，易于使用，流程如图所示。其中对数据的归一化、量化、数据排布格式转换、反量化等均在CPU上运行，模型本身的推理在NPU上运行。



(2) 零拷贝API推理：流程如图所示。优化了通用API的数据处理流程，归一化、量化和模型推理都会在NPU上运行，NPU输出的数据排布格式和反量化过程在CPU或者NPU上运行。零拷贝API对于输入数据流程的处理效率会比通用API高。支持数据在不同的IP核之间流动，没有数据拷贝，减少CPU及DDR带宽消耗。比如通过camera或者解码出来的数据，支持零拷贝导入到NPU中使用。



当用户输入数据只有虚拟地址时，只能使用通用API接口；当用户输入数据有物理地址或fd时，两组接口都可以使用。