

10.均值和标准差

1. rknn.config()的标准化参数

rknn.config()里有两个参数：均值mean_values和标准差std_values，这两个参数用于对输入的图片数据进行特征缩放，使得输入的图片数据位于较小的范围之内。经过这两个参数特这个缩放后，新的输入数据：

代码块

```
1 // 新数据 = (原数据- 均值) / 标准差
2 标准化的值 = (X - mean_values)/std_values
3
4 // 若均值mean_values = 127.5，标准差std_values = 127.5，则经过特征缩放后，输入的数据
   被归一化
5 // 到[-1,1]之间，输入的图片数据，最小是0，最大是255，代入以上计算公式：
6
7 标准化的值 = (0 - 127.5)/127.5 = -1
8 标准化的值 = (255 - 127.5)/127.5 = 1
```

一般原则：

一般模型在训练的时候，输入的数据进行了什么预处理，在模型推理的时候，也要对输入的数据进行什么样的预处理，训练和推理的数据要保持一致，如：RGB通道排序、标准化/归一化范围、数据矩阵表示（是NHWC还是NCHW）等等，要尽量保持一致，否则，可能会影响模型推理的准确度。

2. 标准化和归一化

标准化（Standardization）和归一化（Normalization）都是对数据进行特征缩放的，可以对数据进行线性变换。

归一化

归一化通常是指将数据缩放到特定的范围，从广义上来说，可以是各种范围，常见的，就是缩放到[0, 1]或者[-1,1]的范围。常见的归一化公式：

- 最小-最大归一化

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

- 均值归一化


$$x' = \frac{x - \bar{x}}{\max(x) - \min(x)} \text{ 其中, } \bar{x} = average(x)$$

x' 表示缩放后的值， x 表示原始值， $\min(x)$ 是该特征向量的最小值， $\max(x)$ 是该特征向量的最大值， $\bar{x}$ 表示该特征向量的平均值

标准化

标准化通常是指将特征数据缩放到均值为0、标准差为1的分布中，即：将特征数据变换为服从均值为0，标准差为1的标准正态分布（记为 $N(0, 1)$ ）。标准化公式：

- 标准化（Z-score）


$$\begin{aligned} x' &= \frac{x - \bar{x}}{\sigma} \\ \bar{x} &= average(x) \\ \sigma &= \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2} \end{aligned}$$

x' 表示缩放后的值， x 表示原始值， $\bar{x}$ 表示该特征向量的平均值， σ 是该特征向量的标准差。

标准化的目标，是把一堆高低胖瘦各不相同的数据，统一'压缩平移'成一个标准的形态：让它们的平均值变成0，离散程度（标准差）变成1

举例说明

为什么要对数据进行标准化或归一化处理？

假设我们要预测房价，模型的计算公式为：

房价 = $W_1 \times$ 房间数 + $W_2 \times$ 面积数。

原始数据：

房子	房间数	面积
A	2	80
B	3	110
C	5	150
D	7	200

方法1：归一化（Min-Max）

房间数：min=2, max=7

房子	原始值	计算过程	归一化结果
A	2	$(2-2)/(7-2)$	0
B	3	$(3-2)/(7-2)$	0.2
C	5	$(5-2)/(7-2)$	0.6
D	7	$(7-2)/(7-2)$	1

面积数：min=80, max=200

房子	原始值	计算过程	归一化结果
A	80	$(80-80)/(200-80)$	0
B	110	$(110-80)/(200-80)$	0.25
C	150	$(150-80)/(200-80)$	≈ 0.583
D	200	$(200-80)/(200-80)$	1

方法2：标准化（Z-score） [-3, 3]

房间数：均值 $\bar{x} = 4.25$ ，标准差 $\sigma \approx 1.92$

房子	原始值	计算过程	标准化结果
A	2	$(2-4.25)/1.92 = -2.25/1.92$	-1.17
B	3	$(3-4.25)/1.92 = -1.25/1.92$	-0.65
C	5	$(5-4.25)/1.92 = 0.75/1.92$	0.39
D	7	$(7-4.25)/1.92 = 2.75/1.92$	1.43

面积数：均值 $\bar{x} = 135$ ，标准差 $\sigma = 45$

房子	原始值	计算过程	标准化结果
----	-----	------	-------

A	80	$(80-135)/45 = -55/45$	-1.22
B	110	$(110-135)/45 = -25/45$	-0.56
C	150	$(150-135)/45 = 15/45$	0.33
D	200	$(200-135)/45 = 65/45$	1.44

两种方法结果对比

房子	归一化 (房间,面积)	标准化 (房间,面积)
A	(0, 0)	(-1.17, -1.22)
B	(0.2, 0.25)	(-0.65, -0.56)
C	(0.6, 0.583)	(0.39, 0.33)
D	(1, 1)	(1.43, 1.44)

关键场景对比

场景1：数据中出现异常值

假设数据中多了一套超级豪宅：E房子（房间数=20，面积=800）

归一化后的结果：

房子	房间数 (原始)	归一化结果	问题
A	2	$(2-2)/(20-2)=0$	
B	3	$(3-2)/(20-2)=1/18\approx0.056$	⚠ 正常房子被压缩到
C	5	$(5-2)/(20-2)=3/18\approx0.167$	⚠ [0, 0.33] 的狭窄区间
D	7	$(7-2)/(20-2)=5/18\approx0.278$	⚠ 难以区分
E	20	$(20-2)/(20-2)=1$	异常值占满整个范围

标准化后的结果：

房子	房间数 (原始)	标准化结果	优势
A	2	$(2-7.4)/6.96 \approx -0.78$	✅ 正常房子仍分布在
B	3	$(3-7.4)/6.96 \approx -0.63$	✅ [-0.8, 0.8] 区间
C	5	$(5-7.4)/6.96 \approx -0.34$	✅ 保持可区分性
D	7	$(7-7.4)/6.96 \approx -0.06$	✅
E	20	$(20-7.4)/6.96 \approx 1.81$	异常值单独远离

结论：标准化对异常值不敏感，正常数据不会被压缩。

场景2：新数据超出训练范围

模型部署后，来了一个新房源：F房子（房间数=8，训练时最大值=7）

方法	计算过程	结果	是否可用
归一化	$(8-2)/(7-2)=6/5$	1.2	❌ 超出 [0,1] 范围
标准化	$(8-4.25)/1.92=3.75/1.92$	1.95	✅ 仍在合理范围内

结论：标准化可以处理训练集范围之外的新数据，归一化则不能

标准化/归一化的好处？

- 加快梯度下降求解最优解的速度，减少迭代次数；
- 提高模型的精度，在一定程度上提高模型的训练效果；
- 使不同特征具有可比性；
- 适配硬件与量化需求,小范围数据在 INT8 量化时信息损失更少；

什么时候选择标准化，什么时候选择归一化？

场景	推荐方法	原因
知道数据的最大值和最小值，且无异常值	归一化	简单高效，输出范围固定
数据量庞大，特征最大值/最小值未知	标准化	不需要边界信息
数据存在极端最大值或最小值	标准化	避免正常数据被压缩
数据存在孤立点/异常值	标准化	对异常值更鲁棒
深度学习模型预处理（如ResNet）	标准化	模型通常以此预训练
需要输出到固定范围（如图像像素0-255）	归一化	输出范围可控
不确定用哪个	标准化	更安全、更通用

3. 预训练模型的参数值

框架	模型	输入形状	输入类型	归一化 μ	归一化 σ
Tensorflow Lite	ResNet50	224x224x3	BGR	(103.939,116.779,123.68)	(1.0,1.0,1.0)
	InceptionV3	299x299x3	RGB	(127.5,127.5,127.5)	(127.5,127.5,127.5)
	DenseNet121	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
	SqueezeNet	224x224x3	RGB	(127.5,127.5,127.5)	(255.0,255.0,255.0)
	MobileNetV2	224x224x3	RGB	(127.5,127.5,127.5)	(127.5,127.5,127.5)
	MnasNet	224x224x3	RGB	(127.5,127.5,127.5)	(127.5,127.5,127.5)
Caffe2	ResNet50	224x224x3	BGR	(127.5,127.5,127.5)	(127.5,127.5,127.5)
	InceptionV3	299x299x3	BGR	(127.5,127.5,127.5)	(127.5,127.5,127.5)
	DenseNet121	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
	SqueezeNet	224x224x3	BGR	(127.5,127.5,127.5)	(1.0,1.0,1.0)
	MobileNetV2	224x224x3	BGR	(103.53,116.28,123.675)	(57.375,57.12,58.395)
	MnasNet	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
Pytorch Mobile	ResNet50	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
	InceptionV3	299x299x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
	DenseNet121	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
	SqueezeNet	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
	MobileNetV2	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)
	MnasNet	224x224x3	RGB	(123.675,116.28,103.53)	(58.395,57.12,57.375)

模型	mean_values	std_values
ResNet系列	[123.675, 116.28, 103.53]	[58.395, 58.395, 58.395]
MobileNet系列	[127.5, 127.5, 127.5]	[127.5 ,127.5, 127.5]
VGG系列	[123.68,116,779,103.939]	[58.393,57.12,57.375]
AlexNet系列	[123.68,116,779,103.939]	[58.393,57.12,57.375]
EfficientNet系列	[127.5, 127.5, 127.5]	[127.5, 127.5, 127.5]
InceptionV3系列	[127.5, 127.5, 127.5]	[127.5, 127.5, 127.5]

