

13.rknn-toolkit2模型推理

1. API介绍

1.1 加载RKNN模型

API	load_rknn
描述	加载RKNN模型。 加载完RKNN模型后，不需要再进行模型配置、模型加载和构建RKNN模型的步骤。并且加载后的模型仅限于连接NPU硬件进行推理或获取性能数据等，不能用于模拟器或精度分析等。
参数	path: RKNN模型文件路径。
返回值	0: 加载成功。
	-1: 加载失败。

举例如下：

代码块

```
1  # 从当前路径加载mobilenet_v1.rknn模型
2  ret = rknn.load_rknn(path='./mobilenet_v1.rknn')
```

1.2 初始化运行时环境

在模型推理或性能评估之前，必须先初始化运行时环境，明确模型的运行平台（具体的目标硬件平台或软件模拟器）。

API	init_runtime
描述	初始化运行时环境。
参数	target: 目标硬件平台，支持“rv1103”、“rv1103b”、“rv1106”、“rv1106b”、“rv1126b”、“rk3562”、“rk3566”、“rk3568”、“rk3576”和“rk3588”。默认值为None，即在PC使用工具时，模型在模拟器上运行。注：target设为None时，需要先调用build或hybrid_quantization接口才可让模型在模拟器上运行。
	device_id: 设备编号，如果PC连接多台设备时，需要指定该参数，设备编号可以通过“list_devices”接口查看。默认值为None。
	perf_debug: 进行性能评估时是否开启debug模式。在debug模式下，可以获取到每一层的运行时间，否则只能获取模型运行的总时间。默认值为False。
	eval_mem: 是否进入内存评估模式。进入内存评估模式后，可以调用eval_memory接口获取模型运行时的内存使用情况。默认值为False。
	async_mode: 是否使用异步模式。默认值为False。 调用推理接口时，涉及设置输入图片、模型推理、获取推理结果三个阶段。如果开启了异步模式，设置当前帧的输入将与推理上一帧同时进行，所以除第一帧外，之后的每一帧都可以隐藏设置输入的时间，从而提升性能。在异步模式下，每次返回的推理结果都是上一帧的。 (目前版本该参数暂不支持)

API	init_runtime
	core_mask: 设置运行时的NPU核心。支持的平台为RK3588 / RK3576，支持的配置如下： RKNN.NPU_CORE_AUTO: 表示自动调度模型，自动运行在当前空闲的NPU核上。 RKNN.NPU_CORE_0: 表示运行在NPU0核心上。 RKNN.NPU_CORE_1: 表示运行在NPU1核心上。 RKNN.NPU_CORE_2: 表示运行在NPU2核心上。 RKNN.NPU_CORE_0_1: 表示同时运行在NPU0、NPU1核心上。 RKNN.NPU_CORE_0_1_2: 表示同时运行在NPU0、NPU1、NPU2核心上。 RKNN.NPU_CORE_ALL: 表示根据平台自动配置NPU核心数量。 默认值为RKNN.NPU_CORE_AUTO。 注：RK3576只有2个核心，因此不能设置NPU_CORE_2和NPU_CORE_0_1_2。
	fallback_prior_device: 设置当OP超出NPU规格时fallback的优先级，当前支持“cpu”或“gpu”，“gpu”只有在存在GPU硬件的平台上有效。默认值是“cpu”。
返回值	0: 初始化运行时环境成功。
	-1: 初始化运行时环境失败。

举例如下：

代码块

```
1 # 初始化运行时环境
2 ret = rknn.init_runtime(target='rk3566')
3 ret = rknn.init_runtime(target=None)
```

1.3 模型推理

在进行模型推理前，必须先构建或加载一个RKNN模型。

API	inference
描述	对当前模型进行推理，并返回推理结果。 如果初始化运行环境时有设置target为Rockchip NPU设备，得到的是模型在硬件平台上的推理结果。如果没有设置target，得到的则是模型在模拟器上的推理结果。
参数	inputs: 待推理的输入列表，格式为ndarray。 data_format: 输入数据的layout列表，“nchw”或“nhwc”，只对4维的输入有效。默认值为None，表示所有输入的layout都为NHWC。 inputs_pass_through: 输入的透传列表。默认值为None，表示所有输入都不透传。 非透传模式下，在将输入传给NPU驱动之前，工具会对输入进行减均值、除方差等操作；而透传模式下，不会做这些操作，而是直接将输入传给NPU。 该参数的值是一个列表，比如要透传input0，不透传input1，则该参数的值为[1, 0]。
返回值	results: 推理结果，类型是ndarray list。

举例如下：

代码块

```
1 # 使用模型对图片进行推理，得到TOP5结果
2 outputs = rknn.inference(inputs=[img])
3 show_outputs(outputs)
```

输出的TOP5结果如下：

代码块

```
1 -----TOP 5-----
2 [ 156] score:0.928223 class:"Shih-Tzu"
3 [ 155] score:0.063171 class:"Pekinese, Pekingese, Peke"
4 [ 205] score:0.004299 class:"Lhasa, Lhasa apso"
5 [ 284] score:0.003096 class:"Persian cat"
```

2. 代码测试

03_rknn_inference

2.1 模拟器测试

代码块

```
1  from rknn.api import RKNN
2  import cv2
3  import numpy as np
4
5  def show_outputs(output):
6      output_sorted = sorted(output, reverse=True)
7      top5_str = '\n-----TOP 5-----\n'
8      for i in range(5):
9          value = output_sorted[i]
10         index = np.where(output == value)
11         for j in range(len(index)):
12             if (i + j) >= 5:
13                 break
14             if value > 0:
15                 topi = '{}: {}\n'.format(index[j], value)
16             else:
17                 topi = '-1: 0.0\n'
18             top5_str += topi
19     print(top5_str)
20
21
22 def softmax(x):
23     return np.exp(x)/sum(np.exp(x))
24
25 if __name__ == '__main__':
26     rknn = RKNN(verbose=False)
27
28     rknn.config(
29         mean_values=[[123.675,116.28,103.53]],
30         std_values=[[58.395, 58.395, 58.395]],
31         target_platform="rk3588"
32     )
33
```

```

34     rknn.load_pytorch(model="./resnet18.pt", input_size_list=[[1, 3, 224,
224]])
35
36     rknn.build(
37         do_quantization=True,
38         dataset="./dataset.txt",
39     )
40
41     rknn.export_rknn(export_path="resnet18.rknn")
42
43     # 调用init_runtime接口初始化运行时环境
44     rknn.init_runtime(
45         target=None, # target 表示RKNN模型运行平台
46         device_id=None,
47         perf_debug=False, # perf_debug 设置为True, 可以打开性能评估的debug模式
48         eval_mem=False, # eval_mem设置为True, 表示使能内存评估模式
49         async_mode=False, # 表示是否使能异步模式
50         core_mask=RKNN.NPU_CORE_AUTO, # 可以设置运行时NPU的核心
51     )
52
53     # 使用opencv获取要推理的图片数据
54     img = cv2.imread(
55         filename="./space_shuttle_224.jpg", # 表示要读取的图片路径
56         flags=None
57     )
58     # 扩展为4维度
59     img = np.expand_dims(img, axis=0)
60
61     # cvtColor 继续图像数据格式转化
62     cv2.cvtColor(
63         src=img, # 表示要转换的数据
64         code=cv2.COLOR_BGR2RGB, # code表示转换码
65     )
66
67     # 调用inference接口进行推理测试
68     outputs = rknn.inference(
69         inputs=[img], # inputs表示要推理的数据
70         data_format="nhwc", # data_format表示要推理的数据模式
71     )
72
73     # 对outputs进行后处理
74     show_outputs(softmax(np.array(outputs[0][0])))
75
76     rknn.release()

```

结果:

2.2 连板推理测试

```

1  from rknn.api import RKNN
2  import cv2
3  import numpy as np
4
5  def show_outputs(output):
6      output_sorted = sorted(output, reverse=True)
7      top5_str = '\n-----TOP 5-----\n'
8      for i in range(5):
9          value = output_sorted[i]
10         index = np.where(output == value)
11         for j in range(len(index)):
12             if (i + j) >= 5:
13                 break
14             if value > 0:
15                 topi = '{}: {} \n'.format(index[j], value)
16             else:
17                 topi = '-1: 0.0 \n'
18             top5_str += topi
19         print(top5_str)
20
21
22  def softmax(x):
23      return np.exp(x)/sum(np.exp(x))
24
25  if __name__ == '__main__':
26      rknn = RKNN(verbose=True)
27

```

```

28     # 调用load_rknn接口直接加载RKNN模型
29     rknn.load_rknn(path="./resnet18.rknn")
30
31     # 调用init_runtime接口初始化运行时环境
32     rknn.init_runtime(
33         target="rk3588", # target 表示RKNN模型运行平台
34         device_id=None,
35         perf_debug=False, # perf_debug 设置为True, 可以打开性能评估的debug模式
36         eval_mem=False, # eval_mem设置为True, 表示使能内存评估模式
37         async_mode=False, # 表示是否使能异步模式
38         core_mask=RKNN.NPU_CORE_AUTO, # 可以设置运行时NPU的核心
39     )
40
41     # 使用opencv获取要推理的图片数据
42     img = cv2.imread(
43         filename="./space_shuttle_224.jpg", # 表示要读取的图片路径
44         flags=None
45     )
46
47     # 扩展为4维度
48     img = np.expand_dims(img, axis=0)
49
50     # cvtColor 继续对数据格式转化
51     cv2.cvtColor(
52         src=img, # 表示要转换的数据
53         code=cv2.COLOR_BGR2RGB, # code表示转换码
54     )
55
56     # 调用inference接口进行推理测试
57     outputs = rknn.inference(
58         inputs=[img], # inputs表示要推理的数据
59         data_format="nhwc", # data_format表示要推理的数据模式
60     )
61
62     # 对outputs进行后处理
63     show_outputs(softmax(np.array(outputs[0][0])))
64
65     rknn.release()

```

[查看结果](#)

```
(rknn-toolkit2) topeet@ubuntu:~/rknn/04_code/03_rknn_inference$ python rknn_inference.py
I rknn-toolkit2 version: 2.3.2
D adb path: /home/topeet/miniconda3/envs/rknn-toolkit2/lib/python3.8/site-packages/rknn/3rdparty/platform-tools/adb/linux-x86_64/adb
adb: unable to connect for root: closed
I target set by user is: rk3588
D adb path: /home/topeet/miniconda3/envs/rknn-toolkit2/lib/python3.8/site-packages/rknn/3rdparty/platform-tools/adb/linux-x86_64/adb
I Get hardware info: target_platform = rk3588, os = Linux, aarch = aarch64
I Check RK3588 board npu runtime version
I Starting ntp or adb, target is RK3588
I Start adb...
I Connect to Device success!
I NPUTransfer(949167): Starting NPU Transfer Client, Transfer version 2.2.2 (12abf2a@2024-09-02T03:22:41)
D NPUTransfer(949167): Transfer spec = local:transfer_proxy
D NPUTransfer(949167): Transfer interface successfully opened, fd = 3
I NPUTransfer(949167): TransferBuffer: min aligned size: 1024
D RKNNAPI: =====
D RKNNAPI: RKNN VERSION:
D RKNNAPI:   API: 2.3.2 (1842325 build@2025-03-30T09:55:23)
D RKNNAPI:   DRV: rknn_server: 2.3.2 (1842325 build@2025-03-30T09:54:34)
D RKNNAPI:   DRV: rknnrt: 2.3.2 (429f97ae6b@2025-04-09T09:09:27)
D RKNNAPI: =====
D RKNNAPI: Input tensors:
D RKNNAPI:   index=0, name=x.3, n_dims=4, dims=[1, 224, 224, 3], n_elems=150528, size=150528, w_stride = 0, size_with_stride = 0, fmt=NHWC, type=INT8, qnt_type=AFFINE, zp=-13, scale=0.018478
D RKNNAPI: Output tensors:
D RKNNAPI:   index=0, name=572, n_dims=2, dims=[1, 1000], n_elems=1000, size=1000, w_stride = 0, size_with_stride = 0, fmt=UNDEFINED, type=INT8, qnt_type=AFFINE, zp=-70, scale=0.118524

-----TOP 5-----
[812]: 0.9993157386779785
[404]: 0.00040032254764810205
[833]: 3.7404817703645676e-05
[814]: 3.32241143041756e-05
[657 744]: 2.951068563561421e-05

D NPUTransfer(949167): Transfer client closed, fd = 3
```