

15.模型性能评估

1. 性能评估流程



2. 性能评估API介绍

API	eval_perf
描述	评估模型性能。 模型必须运行在与PC连接的RV1103 / RV1103B / RV1106 / RV1106B / RV1126B / RK3562 / RK3566 / RK3568 / RK3576 / RK3588上。如果调用“init_runtime”的接口来初始化运行环境时设置perf_debug为False，则获得的是模型在硬件上运行的总时间；如果设置perf_debug为True，除了返回总时间外，还将返回每一层的耗时情况。
参数	is_print: 是否打印性能信息，默认值为True。
	fix_freq: 是否固定硬件设备的频率，默认值为True。
返回值	perf_result: 性能信息（字符串）。

接口 rknn.eval_perf() 会输出当前的硬件频率并获取模型的性能评估结果， fix_freq 参数表示是否需要尝试对硬件（包括CPU/NPU/DDR）定频，如果要对硬件定频则设置成 True，否则设置成 False，默认值为True。

若初始化时 rknn.init_runtime() 的 perf_debug 参数设置为 True，将输出每一层的耗时情况和总耗时情况，若为 False 则只输出总耗时情况。

3. 代码测试

06_eval_perf

代码块

```

1  from rknn.api import RKNN
2
3  if __name__ == '__main__':
4      rknn = RKNN()
5
6      # 使用load_rknn接口导入rknn模型
7      rknn.load_rknn(path="./resnet18.rknn")
8
9      # 使用init_runtime接口初始化运行时环境
10     rknn.init_runtime(
11         target="rk3588",
12         perf_debug=True, # perf_debug表示是否开启性能评估的debug模式
13     )
14
15     # 使用eval_perf接口进行性能评估
16     rknn.eval_perf(
17         is_print=True, # is_print 表示使能打印性能信息
18         fix_freq=True # 是否固定频率

```

```
19    )
20
21    rknn.release()
```

不开启性能评估

```
I You can set perf_debug to True in init_runtime to get more detail performance information!
Total Time(us): 4154
FPS: 240.73
```

开启性能评估

```
Total Operator Elapsed Per Frame Time(us): 4794
Total Internal Memory Read/Write Per Frame Size(KB): 8568.36
Total Weight Memory Read/Write Per Frame Size(KB): 11567.50
Total Memory Read/Write Per Frame Size(KB): 20135.86
```

Operator Time Consuming Ranking Table

OpType	CallNumber	CPUTime(us)	GPUTime(us)	NPUTime(us)	TotalTime(us)	TimeRatio(%)
ConvRelu	9	0	0	2499	2499	52.13%
ConvAdd	8	0	0	1408	1408	29.37%
Relu	8	0	0	358	358	7.47%
Conv	5	0	0	251	251	5.24%
MaxPool	1	0	0	234	234	4.88%
Reshape	1	28	0	0	28	0.58%
InputOperator	1	8	0	0	8	0.17%
OutputOperator	1	8	0	0	8	0.17%
Total		44	0	4750	4794	

性能评估结果各字段说明如下表：

字段	详细说明
ID	算子编号
OpType	算子类型
Data Type	输入的数据类型
Target	算子运行的硬件（CPU/NPU/GPU）
InputShape	输入形状
OutputShape	输出形状
DDRCycles	DDR读写时钟周期数
NPUCycles	NPU计算时钟周期数
MaxCycles	DDR Cycles和NPU Cycles的最大值
Time(us)	算子计算耗时（us）
MacUsage(%)	MAC使用率
WorkLoad(0/1/2)	0/1/2核负载情况（仅RK3588平台）
WorkLoad(0/1)	0/1核负载情况（仅RK3576平台）
TaskNumber	NPU任务数
RW(KB)	读写的数据总量（KB）
FullName	算子全名
Total Operator Elapsed Per Frame Time(us)	模型推理的单帧总耗时
Total Memory Read/Write Per Frame Size(KB)	模型推理的单帧总带宽消耗
CallNumber	单帧内该算子运行次数
CPUTime(us)	单帧内该算子在CPU上的总耗时
GPUPTime(us)	单帧内该算子在GPU上的总耗时
NPUTime(us)	单帧内该算子在NPU上的总耗时
TotalTime(us)	单帧内该算子的总耗时
TimeRatio(%)	单帧内该算子的总耗时与单帧总耗时的比值

4. 最简单的一种性能优化方式

官方脚本：https://github.com/airockchip/rknn_model_zoo/blob/main/scaling_frequency.sh

直接把CPU、DDR、NPU频率搞最高就行。