

16.模型内存评估

1. 模型内存评估流程



2. API接口

API	eval_memory
描述	获取模型在硬件平台运行时的内存使用情况。 模型必须运行在与PC连接的RV1103 / RV1103B / RV1106 / RV1106B / RV1126B / RK3562 / RK3566 / RK3568 / RK3576 / RK3588上。
参数	is_print : 是否以规范格式打印内存使用情况，默认值为True。
返回值	memory_detail : 内存使用情况，类型为字典。内存使用情况按照下面的格式封装在字典中： { 'weight_memory': 3698688, 'internal_memory': 1756160, 'other_memory': 484352, 'total_memory': 5939200, } - 'weight_memory' 字段表示运行时模型权重的内存占用。 - 'internal_memory' 字段表示运行时模型中间tensor内存占用。 - 'other_memory' 字段表示运行时其他的内存占用。 - 'total_model_allocation' 表示运行时的总内存占用，即权重、中间tensor和其他的内存占用之和。

举例如下：

代码块

```
1  # 对模型内存使用情况进行评估
2  memory_detail = rknn.eval_memory()
```

内存评估结果如下：

代码块

```
1  =====
2  Memory Profile Info Dump
3  =====
4  NPU model memory detail(bytes):
5  Weight Memory: 3.53 MiB
6  Internal Tensor Memory: 1.67 MiB
7  Other Memory: 473.00 KiB
8  Total Memory: 5.66 MiB
9  INFO: When evaluating memory usage, we need consider
10 the size of model, current model size is: 4.09 MiB
11 =====
```

内存评估结果各字段说明如下：

字段	详细说明
Total Weight Memory	模型中权重的内存占用（MB）
Total Internal Tensor Memory	模型中间 tensor 内存占用（MB）
Other Memory	其他内存占用（例如寄存器配置、输入输出tensor）（MB）
Total Memory	模型的内存总占用（MB）

3. 代码测试

07_eval_memory

代码块

```
1  from rknn.api import RKNN
2
3  if __name__ == '__main__':
4      rknn = RKNN()
5
6      # 使用load_rknn接口导入rknn模型
7      rknn.load_rknn(path="./resnet18.rknn")
8
9      # 使用init_runtime接口初始化运行时环境
10     rknn.init_runtime(
11         target="rk3588",
12         eval_mem=True, # eval_mem表示是否是能内存评估
13     )
14
15     # 使用eval_memory接口进行内存评估
16     rknn.eval_memory(
17         is_print=True, # 表示使能打印内存评估信息
18     )
19     rknn.release()
```

查看结果

Memory Profile Info Dump

```
=====
NPU model memory detail(bytes):
  Weight Memory: 11.25 MiB
  Internal Tensor Memory: 1.10 MiB
  Other Memory: 169.94 KiB
  Total Memory: 12.52 MiB

INFO: When evaluating memory usage, we need consider
the size of model, current model size is: 11.47 MiB
=====
```